Vigía — Detector de comentarios tóxicos con BERT

Taller Evaluado 03 (T03) · Desarrollo de Soluciones Inteligentes · 23-10-2026

1. Identificación

Proyecto	Vigía — Detector de comentarios tóxicos (BERT) — Civil Comments
Equipo	Equipo D03 (T03_D03_Equipo_MerinoBranco_DiazMatias)
Integrante 1	Branco Merino — Paralelo D03
Integrante 2	Matías Díaz — Paralelo D03

2. Problema y solución

Usuario	Moderador de una plataforma de comentarios.
Propósito	El moderador escribe o pega un comentario y la aplicación indica si es potencialmente tóxico, con la probabilidad asociada. Es una ayuda para priorizar la revisión humana, no un veredicto.
Modelo / técnica	`google-bert/bert-base-uncased` ajustado (fine-tuning) como clasificador binario en el Taller 04. En este taller no se entrena ni se ajusta nada: solo se integra el modelo ya entrenado.
Dataset	Civil Comments (`google/civil_comments`), muestra usada en el T04. Etiqueta: `toxico` = 1 si `toxicity` ≥ 0,5. URL: https://huggingface.co/datasets/google/civil_comments
Interfaz	Vigía: interfaz web básica (Gradio) donde el moderador pega el comentario y ve etiqueta, probabilidad, advertencias y limitación.

3. Contrato y arquitectura

Entrada

Campo	Tipo	Unidad / formato	Regla
texto	str	Texto libre en inglés (único idioma con fiabilidad)	Obligatorio; entre 3 y 5.000 caracteres; no vacío ni solo espacios; al menos una letra

Salida (diccionario)

Campo	Tipo	Significado
etiqueta	str	"Tóxico" o "No tóxico"
prob_toxico	float ∈ [0, 1]	Probabilidad que asigna el modelo a la clase tóxica
confianza	float ∈ [0,5, 1]	Probabilidad de la clase predicha
umbral	float	Umbral de decisión (0,5)
advertencias	list[str]	Avisos que no impiden ejecutar (texto en español u otro idioma; truncado a 256 tokens)
limitacion	str	Limitación relevante para interpretar el resultado

Error vs. advertencia. Un error (`ErrorEntrada`) detiene la ejecución y el modelo no se ejecuta. Una advertencia permite ejecutar, pero avisa que el resultado puede ser menos fiable.

Diagrama de componentes

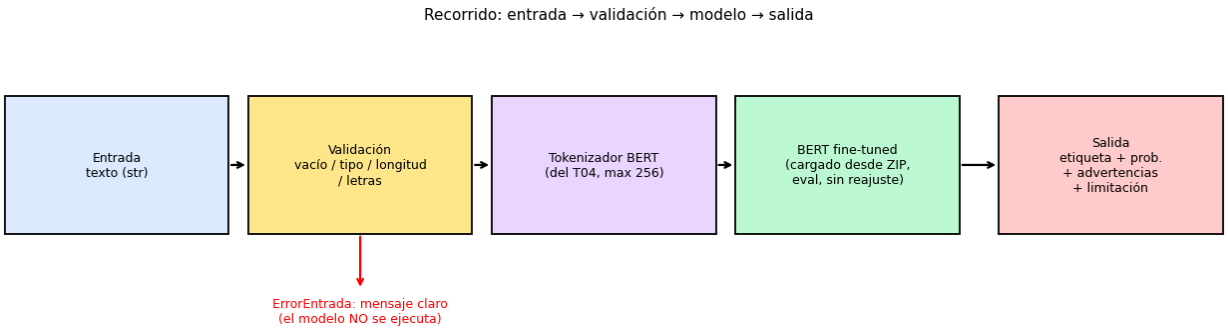

Recorrido: entrada → validación → tokenizador BERT (max 256) → BERT fine-tuned (cargado desde ZIP, eval, sin reajuste) → salida. La rama de error termina en ErrorEntrada sin ejecutar el modelo.

4. Evidencia (salidas del notebook)

Caso válido

```
ENTRADA : 'You are a complete idiot and nobody wants you here.'
SALIDA  : Tóxico  (prob. tóxico = 100.00%, umbral = 0.5)

ENTRADA : "I respectfully disagree with the council's decision,
           but I appreciate the open discussion."
SALIDA  : No tóxico  (prob. tóxico = 0.00%, umbral = 0.5)
```

Caso inválido (el modelo no se ejecuta)

```
ENTRADA : '    '
ERROR DE ENTRADA -> 'texto' está vacío o contiene solo espacios.
(el modelo NO se ejecutó)

ENTRADA : '!!! 123 ???'
ERROR DE ENTRADA -> 'texto' no contiene letras (solo números o símbolos).
```

Otros casos inválidos probados: `12345` → "'texto' debe ser str, pero se recibió int."; `None` → "Falta el campo obligatorio 'texto'."

Caso con advertencia (se ejecuta)

```
ENTRADA : 'Esto es muy malo y no me gusta para nada lo que dices en este comentario.'
SALIDA  : No tóxico  (prob. tóxico = 0.00%, umbral = 0.5)
ADVERTENCIA -> El texto parece estar en español; el modelo solo es fiable en inglés.
En cualquier otro idioma su fiabilidad es nula.
```

Control de pesos: la suma de pesos antes y después de varias predicciones fue idéntica (-640137.2147949659); se verificó modo `eval()` y sin gradientes. Resultado: "Control superado: pesos intactos, modo eval, sin gradientes."

5. Decisión y limitación

Decisión de integración. El modelo y el tokenizador se cargan una sola vez desde el ZIP y se dejan en `eval()` con gradientes desactivados; `predecir()` solo tokeniza y calcula la salida. Se usa el mismo `max_length = 256` del entrenamiento para mantener la correspondencia entre entrenamiento e inferencia. Además se separó error (entrada imposible o inválida: se detiene) de advertencia (se ejecuta, pero se avisa: texto en español o texto truncado).

Limitación. El modelo se entrenó con Civil Comments (principalmente inglés) y con una etiqueta binaria obtenida de un umbral 0,5 sobre una puntuación continua; los comentarios cercanos al umbral son ambiguos. **El modelo solo es fiable en inglés; en cualquier otro idioma su fiabilidad es nula (inexistente).**

Mejora / prueba pendiente. Ampliar el soporte a otros idiomas (por ejemplo, reentrenando con un corpus en español o multilingüe) y calibrar el umbral con un conjunto de validación según el costo de falsos positivos vs. falsos negativos.

6. Reutilización

Base reutilizada	Notebook del Taller 04 (preparación de datos, TF-IDF + Regresión Logística y BERT), dataset Civil Comments (Hugging Face) y `bert-base-uncased`.
Cambios propios	Contrato de entrada/salida, validación con errores y advertencias, función de inferencia, carga desde ZIP, control de pesos intactos, diagrama de arquitectura e interfaz web básica (Vigía, con Gradio).
Herramientas de IA	Claude (Anthropic), para estructurar y redactar funciones del código del notebook.
Verificación	El equipo ejecutó el notebook, revisó cada celda y verificó la salida de los casos válido, inválido y con advertencia (secciones 6 y 7 del notebook).